Технологии больших языковых моделей для задач исследований и разработки (2026)

Правила и билеты для мидтерма

Правила экзамена

- **Оффлайн** экзамен
- Студент получает билет и в течение 10 минут готовится к устному ответу (например, делает заметки), а затем
- Студент в течение 5-7 минут отвечает на вопросы TA/PI и получает оценку (по шкале от 0 до 4).

Критерии оценивания

0 - нет ответа / не явился
1 - четкий письменный ответ + устный ответ с серьезной ошибкой (ошибками) или без устного ответа
2 - четкий письменный ответ + устный ответ с некоторыми незначительными ошибками (ошибками)
3 - четкий письменный ответ + четкий устный ответ
4 - четкий письменный ответ + четкий устный ответ + правильный ответ на дополнительный вопрос от TA/PI

Соотношение баллов: 0 - 0 баллов, 1 - 5 баллов, 2 - 10 баллов, 3 - 15 баллов, 4 - 20 баллов

TA=Teaching Assistant
PI=Primary Instructor

Билеты

Билет 1

1. Что такое n-граммовая языковая модель? Объясните, как она оценивает вероятность предложения.
2. Что такое RLHF? Зачем он применяется и как устроен процесс обучения? В чем отличие RLHF от PPO и DPO?

Билет 2

1. Что такое BPE и WordPiece? Объясните алгоритм обучения токенизатора и его преимущества и ограничения.
2. Что такое IVF-индекс? Объясните принцип его работы и сравните его преимущества и ограничения с полным перебором всех векторов.

Билет 3

1. Что такое KNN-LM? Объясните, как поиск похожих примеров используется языковой моделью при генерации текста, и зачем нужен такой подход.
2. Что такое DPO? Объясните, как работает этот метод и чем он отличается от RLHF.

Билет 4

1. Что такое эмбеддинги текста? Объясните, как они используются для поиска похожих по смыслу документов и в чём ограничения такого поиска. Как работает векторный поиск?
2. Что такое annoy? Объясните, как этот метод ускоряет поиск ближайших векторов и какие компромиссы возникают при его использовании.

Билет 5

1. Что такое bi-encoder и cross-encoder? Объясните, как работает каждый подход, и сравните их плюсы и минусы при поиске документов.
2. Что такое PPO? Объясните принцип работы алгоритма и зачем его применяют при настройке языковых моделей. Приведите другие примеры похожих алгоритмов.

Билет 6

1. Что такое ablation-тест в RAG? Объясните, как его провести и какие выводы можно сделать из результатов.
2. Что такое MCP? Объясните, как он используется в системе с LLM-агентом и чем его роль отличается от роли агента.

Билет 7

1. Что такое BM25? Объясните, как работает этот метод поиска, и назовите его сильные и слабые стороны.
2. Чем отличаются fine-tuning, instruction tuning и alignment? Объясните назначение каждого подхода.

Билет 8

1. Что такое TF-IDF? Объясните, как вычисляется эта мера и зачем она нужна.
2. Из каких этапов состоит цикл работы LLM-агента? Объясните назначение каждого этапа и почему цикл может повторяться.

Билет 9

1. Зачем в RAG-системе нужен поиск документов? Объясните, как найденные фрагменты используются при формировании ответа.
2. Что такое semantic chunking? Объясните алгоритм и в каких случаях он может оказаться полезным или неудачным. Приведите примеры других способы деления на чанки.

Билет 10

1. Как можно объединить поиск по смыслу и поиск по ключевым словам? Объясните принцип гибридного поиска, его преимущества и ограничения.
2. Что такое LLM-агент? Объясните, чем он отличается от обычной языковой модели и как решает задачи, требующие нескольких действий.

Счастливый билет

1. Вы в праве самостоятельно выбрать оба вопроса, на которые будете отвечать.